

ACADÉMIE DES MATHÉMATIQUES APPLIQUÉES

Thème 3 · Réseaux, incertitude et optimisation — Groupe 1

Formulation d'optimisation et descente de gradient projetée

Section du rapport — contribution du Membre 4

Distribuer l'eau équitablement dans un quartier, quand la demande est incertaine

Auteure : Aïchatou Traoré (Membre 4)

Superviseur : Ir. Charbel Mamlankou

Août 2026

0. Objet de cette section

Cette section couvre la partie du projet confiée au Membre 4 : formuler mathématiquement le problème d'optimisation pénalisé, en démontrer la convexité, dériver complètement le gradient, poser l'algorithme de descente de gradient projetée, établir ses conditions théoriques de convergence, et analyser la sensibilité du résultat à l'hyperparamètre de pénalisation μ . Conformément à la contrainte méthodologique du sujet, aucune formule n'est codée avant d'avoir été dérivée intégralement à la main ci-dessous ; le code correspondant, livré séparément par le Membre 5, applique exactement les résultats établis ici.

Toutes les valeurs numériques d'illustration (réseau à deux conduites) sont des exemples pédagogiques simplifiés servant à vérifier chaque résultat ; les valeurs issues du réseau réel du projet ($\kappa(A) \approx 4,72$, $\lambda_{\max}(A^T A) \approx 6,25$) proviennent de l'analyse algébrique du Membre 2.

1. Formulation du problème pénalisé

1.1 Rappel du problème contraint

Le sujet impose de chercher le vecteur de débits $q \in \mathbb{R}^{13}$ qui minimise le coût de transport, sous deux contraintes physiques :

$$q^* = \operatorname{argmin}_q \sum_e c_e q_e^2 \quad \text{sous} \quad Aq = b, \quad q \geq 0$$

où A est la matrice d'incidence orientée du réseau (construite par le Membre 2), b regroupe l'offre aux réservoirs et la demande de chaque quartier, et $c_e > 0$ est le coût unitaire de la conduite e (donnée du réseau).

1.2 Principe de la pénalisation

La contrainte méthodologique du sujet interdit explicitement l'usage des multiplicateurs de Lagrange pour traiter $Aq = b$: elle doit être traitée par **pénalisation**. L'idée est de remplacer un problème à contrainte d'égalité stricte par un problème sans contrainte d'égalité, dans lequel on ajoute au coût un terme qui devient très grand dès que la contrainte est violée. Un paramètre $\mu > 0$, appelé **paramètre de pénalisation**, règle l'intensité de cette pénalité.

1.3 Fonction de coût pénalisée $J(q)$

Définition 1 — Fonction de coût pénalisée

$$J(q) = q^T C q + \mu \|Aq - b\|^2$$

où $C = \operatorname{diag}(c_e)$ est la matrice diagonale des coûts unitaires.

Le premier terme, $q^T C q = \sum_e c_e q_e^2$, est le coût réel de transport : chaque conduite coûte proportionnellement au carré du débit qu'elle transporte (modèle physique de pertes de charge). Le second terme, $\mu \|Aq - b\|^2$, est la pénalité : il vaut 0 si et seulement si la conservation des flux est respectée exactement, et croît quadratiquement avec l'écart à cette conservation.

Exemple pédagogique (réseau à 2 conduites)

Réseau : un réservoir R1 alimentant deux quartiers Q1 (demande 4) et Q2 (demande 6), via deux conduites directes, de coûts unitaires $c_1 = c_2 = 1$. Pour $q = (3, 5)$ et $\mu = 10$, le coût de transport vaut $3^2 + 5^2 = 34$, la violation $Aq - b = (2, -1, -1)$ donne une pénalité de $10 \times 6 = 60$, soit $J(q) = 94$.

2. Convexité de $J(q)$

Établir que J est convexe est indispensable : cela garantit qu'un minimum local trouvé par descente de gradient est aussi le minimum global, et qu'il est unique. Sans cette garantie, l'algorithme des sections suivantes n'aurait aucune légitimité théorique.

2.1 Rappel : critère du Hessien**Définition 2 — Fonction convexe / Critère du Hessien**

Une fonction f deux fois différentiable est convexe si et seulement si sa matrice hessienne $\nabla^2 f(x)$ est positive semi-définie en tout point x , c'est-à-dire :

$$x^T H x \geq 0 \quad \text{pour tout } x \in \mathbb{R}^n$$

Si l'inégalité est stricte pour tout $x \neq 0$ (positive définie), f est strictement convexe et admet, si un minimum existe, un unique minimum global.

2.2 Hessien du terme de coût $q^T C q$

Pour toute matrice symétrique M , $\nabla(q^T M q) = 2Mq$ (règle de dérivation matricielle standard, redémontrée en composantes au §3.1). En dérivant une seconde fois, le Hessien de $q^T C q$ est la constante

$$\nabla^2(q^T C q) = 2C.$$

Comme $C = \text{diag}(c_e)$ est diagonale avec $c_e > 0$ pour toute conduite (coût unitaire, donnée du réseau), toutes les valeurs propres de $2C$ sont strictement positives : $2C$ est **positive définie**.

2.3 Hessien du terme de pénalisation

En développant $(Aq - b)^T(Aq - b) = q^T A^T A q - 2b^T A q + b^T b$ (en utilisant que $q^T A^T b = b^T A q$ car ce sont des scalaires égaux à leur propre transposée), on obtient par les mêmes règles de dérivation :

$$\nabla^2[\mu \|Aq - b\|^2] = 2\mu A^T A.$$

Pour toute matrice A et tout vecteur x , $x^T(A^T A)x = \|Ax\|^2 \geq 0$: $A^T A$ est donc *toujours* positive semi-définie, sans aucune hypothèse supplémentaire — mais pas nécessairement définie : le Membre 2 a établi que $A^T A$ possède un noyau de dimension 4 sur le réseau du projet (les 4 cycles indépendants), donc 4 valeurs propres nulles.

2.4 Convexité de J : démonstration**Proposition 1 — Stricte convexité de J**

$$\nabla^2 J(q) = 2C + 2\mu A^T A \succ 0 \quad \text{pour tout } q \text{ (et tout } \mu > 0)$$

Démonstration. Pour tout $q \neq 0$:

$$q^T(2C + 2\mu A^T A)q = q^T(2C)q + q^T(2\mu A^T A)q$$

Le premier terme est strictement positif car $2C$ est positive définie (§2.2). Le second terme est au minimum nul, jamais négatif, car $A^T A$ est positive semi-définie (§2.3). La somme d'un terme strictement positif et d'un terme non négatif est strictement positive. ■

Résultat clé : la convexité de J ne dépend **pas** du conditionnement de A , ni de sa connexité, ni de la valeur de μ — elle découle uniquement du fait que chaque coût unitaire c_e est strictement positif. C'est un résultat robuste, valable pour n'importe quelle topologie de réseau respectant les hypothèses du sujet.

2.5 Conséquence pratique

J étant strictement convexe (et quadratique, donc de Hessian constant), elle admet un **unique** minimum global sur $\mathbb{R}^{13}$. La descente de gradient, correctement réglée (Section 5), est donc garantie de converger vers ce minimum, et non vers un optimum local parmi plusieurs.

3. Dérivation complète du gradient $\nabla J(q)$

3.1 Règle de dérivation : $\nabla(q^T M q) = 2Mq$ pour M symétrique

Cette règle, utilisée deux fois ci-dessous, se redémontre simplement en composantes. Pour M symétrique ($M_{ij} = M_{ji}$), $q^T M q = \sum_i \sum_j M_{ij} q_i q_j$.

En dérivant par rapport à q_k , le terme q_k apparaît deux fois dans la double somme (une fois via $i=k$, une fois via $j=k$) :

$$\partial(q^T M q) / \partial q_k = \sum_j M_{kj} q_j + \sum_i M_{ik} q_i = 2 \sum_j M_{kj} q_j$$

(la dernière égalité utilise $M_{ik} = M_{ki}$), ce qui est exactement la k -ième composante de $2Mq$. D'où $\nabla(q^T M q) = 2Mq$.

3.2 Gradient du terme de coût

Avec $M = C$ (symétrique, diagonale) :

$$\nabla(q^T C q) = 2Cq$$

3.3 Gradient du terme de pénalisation

En reprenant le développement du §2.3 et en dérivant terme à terme :

- $q^T(A^T A)q$: de la forme $q^T M q$ avec $M = A^T A$ symétrique $\rightarrow$ gradient $2A^T A q$ (§3.1)
- $-2b^T A q$: forme linéaire $v^T q$ avec $v = -2A^T b \rightarrow$ gradient $v = -2A^T b$
- $b^T b$: constante (ne dépend pas de q) $\rightarrow$ gradient nul

En sommant :

$$\nabla[\mu\|Aq - b\|^2] = 2\mu(A^T A q - A^T b) = 2\mu A^T(Aq - b)$$

3.4 Résultat final et vérification de cohérence

Résultat — Gradient complet

$$\nabla J(q) = 2Cq + 2\mu A^T(Aq - b)$$

Vérification : re-dériver ce gradient redonne $\nabla^2 J(q) = 2C + 2\mu A^T A$, exactement le Hessian établi au §2.4 — cohérence attendue entre les deux dérivations.

Interprétation physique : $2Cq$ est la direction qui réduit le coût de transport pur ; $2\mu A^T(Aq - b)$ est la direction qui corrige la violation de la conservation des flux, avec une intensité proportionnelle à μ .

3.5 Vérification numérique (différences finies)

Sur l'exemple à 2 conduites ($q = (3, 5)$, $\mu = 10$), la formule analytique donne $\nabla J(3, 5) = (-54, -50)$. La dérivée numérique par différences finies, $\partial J / \partial q_k \approx [J(q + \varepsilon e_k) - J(q)] / \varepsilon$ avec $\varepsilon = 0,001$, donne $(-53,98, -49,98)$ — en accord avec la formule analytique à l'erreur d'approximation près. Cette technique de vérification (comparer gradient analytique et gradient numérique) sera reprise en test automatique par le Membre 5 avant d'intégrer ∇J au solveur.

4. Algorithme : descente de gradient projetée

4.1 Règle de mise à jour

La descente de gradient avance, à chaque itération, dans la direction opposée au gradient (direction de plus forte décroissance locale de J), avec un pas $\eta > 0$:

$$q_{k+1} = q_k - \eta \nabla J(q_k)$$

soit, en substituant le résultat du §3.4 :

$$q_{k+1} = q_k - \eta(2Cq_k + 2\mu A^T(Aq_k - b))$$

4.2 Projection euclidienne sur $\{q \geq 0\}$

La règle de mise à jour seule ne garantit pas $q \geq 0$. Il faut donc projeter le résultat de chaque itération sur l'ensemble admissible $S = \{q \in \mathbb{R}^{13} : q \geq 0\}$.

Proposition 2 — Projection sur l'orthant positif

Pour $S = \{q \geq 0\}$, la projection euclidienne $\text{Proj}_S(x) = \arg\min_{y \in S} \|y - x\|$ est donnée, composante par composante, par :

$$[\text{Proj}_S(x)]_i = \max(x_i, 0)$$

Démonstration. L'ensemble S se décompose en contraintes indépendantes coordonnée par coordonnée ($q \geq 0 \iff$ chaque $q_i \geq 0$), et la distance au carré $\|y - x\|^2 = \sum_i (y_i - x_i)^2$ se décompose en somme de termes indépendants. Minimiser cette somme sous contraintes indépendantes équivaut à minimiser chaque terme séparément.

Pour une coordonnée x_i , on résout $\min_{y_i \geq 0} (y_i - x_i)^2$:

- si $x_i \geq 0$: le minimum libre $y_i = x_i$ est déjà admissible, donc c'est la solution.
- si $x_i < 0$: la fonction est strictement croissante sur le domaine admissible $y_i \geq 0$ (entièrement à droite du minimum libre), donc le minimum sur ce domaine est atteint au bord, $y_i = 0$.

Dans les deux cas, $y_i = \max(x_i, 0)$. ■

4.3 Algorithme complet : descente de gradient projetée

La règle de mise à jour et la projection se combinent en une seule règle, appliquée à *chaque* itération (et non uniquement à la fin, ce qui changerait fondamentalement le comportement de l'algorithme) :

$$q_{k+1} = \max(q_k - \eta \nabla J(q_k), 0)$$

Pseudo-code (aucun code source, conformément à la contrainte du sujet) :

```
Entrées : A, b, C,  $\mu$ ,  $\eta$ ,  $q_0$  (point de départ), seuil  $\varepsilon$ , itérations max K
k  $\leftarrow$  0
Tant que  $\|\nabla J(q_k)\| > \varepsilon$  et k < K :
    g  $\leftarrow$   $2Cq_k + 2\mu A^T(Aq_k - b)$  (gradient, §3.4)
     $q_{k+1} \leftarrow q_k - \eta \cdot g$  (mise à jour, §4.1)
     $q_{k+1} \leftarrow \max(q_{k+1}, 0)$  (projection, §4.2, composante
par composante)
    k  $\leftarrow$  k+1
Retourner  $q_k$ 
```

5. Conditions de convergence

5.1 Constante de Lipschitz du gradient

Pour une fonction convexe L-lisse, la descente de gradient converge si le pas vérifie $\eta < 2/L$, où L est la constante de Lipschitz du gradient : $\|\nabla J(q_1) - \nabla J(q_2)\| \leq L\|q_1 - q_2\|$ pour tous q_1, q_2 .

Pour une fonction quadratique de Hessien constant H , $\nabla J(q_1) - \nabla J(q_2) = H(q_1 - q_2)$ exactement, et la propriété d'algèbre linéaire $\|Hx\| \leq \lambda_{\max}(H)\|x\|$ (avec égalité pour x aligné sur le vecteur propre dominant) donne la meilleure constante possible :

$$L = \lambda_{\max}(\nabla^2 J) = \lambda_{\max}(2C + 2\mu A^T A)$$

5.2 Borne théorique sur le pas d'apprentissage

Sur le réseau réel du projet, le Membre 2 a calculé $\lambda_{\max}(A^T A) \approx 6,25$ et, pour $\mu = 1$, $L(1) \approx 14,95$. D'où la borne :

$$\eta < 2 / L = 2 / 14,95 \approx 0,1338$$

Toute valeur de η strictement inférieure à cette borne garantit théoriquement la convergence de l'algorithme (§5.1) ; au-delà, l'Expérience 4 du protocole numérique doit faire apparaître oscillation ou divergence.

5.3 Critère d'arrêt

En complément de la borne sur le pas, l'algorithme doit s'arrêter selon l'un de ces critères :

- *norme du gradient* : $\|\nabla J(q_k)\| < \varepsilon$, indiquant la proximité d'un point stationnaire
- *variation du coût* : $|J(q_{k+1}) - J(q_k)| < \varepsilon'$, indiquant une stagnation de la décroissance
- *nombre maximal d'itérations* K : garde-fou évitant une boucle infinie si les seuils ne sont jamais atteints

6. Analyse de sensibilité de l'hyperparamètre μ

6.1 Solution exacte non contrainte en fonction de μ

En annulant le gradient (§3.4), hors contrainte de positivité :

$$(C + \mu A^T A)q = \mu A^T b \quad \Rightarrow \quad q^*(\mu) = \mu(C + \mu A^T A)^{-1} A^T b$$

En réécrivant $q^*(\mu) = ((1/\mu)C + A^T A)^{-1} A^T b$, on voit que lorsque $\mu \rightarrow \infty$, le terme $(1/\mu)C \rightarrow 0$, et $q^*(\mu)$ tend vers la solution qui respecte *exactement* $Aq = b$ au coût minimal — c'est le comportement attendu d'une méthode de pénalisation.

6.2 Effet sur la violation résiduelle

De ce qui précède, $\|Aq^*(\mu) - b\|$ décroît vers 0 quand μ augmente : plus μ est grand, plus la solution respecte précisément la conservation des flux.

6.3 Effet sur le conditionnement et sur $L(\mu)$

Décomposons l'action de $A^T A$ selon deux types de directions (résultats du Membre 2, §4 de son analyse) :

- dans les 4 directions du $\ker(A)$ (cycles indépendants), $A^T A$ agit comme 0 : le Hessien y reste $\approx 2C$, *indépendant de μ*
- dans les 9 directions restantes, la contribution $2\mu A^T A$ croît linéairement avec μ et finit par dominer $2C$

Pour μ suffisamment grand, $L(\mu) \approx 2\mu \cdot \lambda_{\max}(A^T A) \approx 12,5 \mu$ (avec $\lambda_{\max}(A^T A) \approx 6,25$) : $L(\mu)$ croît **linéairement** avec μ , ce qui, via le §5.2, réduit d'autant le pas maximal admissible :

$$\eta_{\max}(\mu) = 2 / L(\mu) \approx 0,16 / \mu$$

6.4 Synthèse du compromis

μ	Violation résiduelle $\ Aq-b\ $	$L(\mu)$ / conditionnement	Pas maximal η	Vitesse de convergence
-------	---------------------------------	----------------------------	--------------------	------------------------

petit	grande	faible	grand	rapide, mais peu fiable sur la contrainte
grand	proche de 0	élevé	petit	lente, mais très fiable sur la contrainte

6.5 Recommandation pratique

Un μ raisonnable assure une violation de contrainte négligeable par rapport à la précision recherchée, sans faire exploser le nombre d'itérations nécessaires. En pratique, la valeur retenue résulte de l'Expérience 3 du protocole numérique ($\mu \in \{1, 10, 100, 1000\}$), en recherchant le point où la violation résiduelle devient suffisamment faible sans que la convergence ne devienne excessivement lente — ce compromis, démontré ici analytiquement, sera confirmé empiriquement par le Membre 5.

7. Conclusion de la section

Les six éléments requis pour cette partie du rapport sont établis : la fonction pénalisée J est formulée et démontrée strictement convexe (Section 2) ; son gradient est dérivé intégralement à la main et vérifié numériquement (Section 3) ; l'algorithme de descente de gradient projetée est posé et justifié, avec la projection démontrée (Section 4) ; les conditions de convergence, notamment la borne $\eta < 2/L(1) \approx 0,1338$, sont établies à partir du conditionnement fourni par le Membre 2 (Section 5) ; enfin, l'influence de μ sur le compromis précision-vitesse est analysée analytiquement (Section 6). Ces résultats forment la base théorique que le Membre 5 traduira en code (modules `objective.py` et `gradient_descent.py`), avant confrontation aux résultats numériques par le Membre 6.

Références bibliographiques

- [1] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004 — chapitres 3 (fonctions convexes) et 9 (méthodes de descente).
- [2] J. Nocedal, S. J. Wright, *Numerical Optimization*, 2e éd., Springer, 2006 — chapitres 2 et 3 (conditions d'optimalité, méthodes de gradient, constante de Lipschitz).
- [3] D. P. Bertsekas, *Nonlinear Programming*, 2e éd., Athena Scientific, 1999 — chapitre sur les méthodes de pénalisation et de projection.
- [4] G. Strang, *Introduction to Linear Algebra*, 5e éd., Wellesley-Cambridge Press, 2016 — formes quadratiques et matrices définies positives.
- [5] Ir. Charbel Mamlankou, *Mathématiques fondamentales pour l'IA*, support de cours, AMA, 2026.
- [6] Document de cadrage du projet, Thème 3 · Groupe 1, AMA, 2026 (plan de projet et feuille de route du groupe).
- [7] Membre 2, Représentation algébrique du réseau, document interne du groupe, 2026 (rang, noyau et conditionnement de A).